

Statistik untuk Psikologi dan Ilmu Sosial

Buku Panduan Praktis untuk Mahasiswa dan Peneliti Muda

Sunu Bagaskara Entin Nurhayati Sari Zakiah Akmal
Titi Sahidah Fitriana Aswin Januarsjaf

30 Agustus 2025

Daftar Isi

Selamat Datang!	1
Tentang Penulis	2
I PENGANTAR STATISTIK	4
1 Pengertian & Sejarah Ringkas Statistik	6
1.1 Definisi Statistik	6
1.2 Sampel dan Populasi	6
1.3 Parameter dan Statistik	7
2 Statistik dalam Penelitian Psikologi	8
3 Jenis-jenis Statistik: Deskriptif & Inferensial	9
Soal Latihan	10
II PERSIAPAN DATA	11
4 Jenis Data	13
4.1 Mengidentifikasi Jenis Data	13
4.2 Penamaan dan Pengkodean Data/Variabel	14
5 Pembersihan Data	15
5.1 Melakukan Analisis Deskriptif	15
5.2 Data Hilang	15
5.3 Data Pencilan	16
6 Akuntabilitas Data	18
Soal Latihan	19
III STATISTIK DESKRIPTIF	20
7 Ukuran Pemusatan Data	22
7.1 <i>Mean</i>	22
7.2 <i>Median</i>	22
7.3 <i>Modus</i>	23
8 Ukuran Penyebaran Data	24
8.1 <i>Range</i>	24

8.2	Varians	25
8.3	Standar Deviasi	26
9	Bentuk Distribusi Data	27
9.1	Kurva Normal	27
9.2	<i>Skewness</i>	29
9.3	Kurtosis	30
9.4	<i>Z-Score</i>	31
IV	STATISTIK INFERENSIAL	32
V	PERBEDAAN RATA-RATA DUA KELOMPOK	33
VI	MEMBANDINGKAN RATA-RATA TIGA ATAU LEBIH KELOMPOK	34
VII	ANALISIS KORELASI	35
VIII	MODEL REGRESI LINEAR	36
	Daftar Pustaka	37

Daftar Gambar

5.1	Outlier dalam boxplot	17
8.1	Visualisasi data dengan: a) varians kecil & b) varians besar	26
9.1	Bentuk kurva normal	27
9.2	Proporsi sebaran data pada kurva normal	28
9.3	Distribusi skewed	29
9.4	Skewness data berdasarkan lokasi tendensi sentral	30
9.5	Visualisai kurtosis dalam distribusi data	30

Daftar Tabel

8.3	Perhitungan simpangan dan varians dua kelompok	25
-----	--	----

Selamat Datang!

Alhamdulillah, akhirnya buku *Statistik untuk Psikologi dan Ilmu Sosial* ini bisa sampai ke tangan Anda. Buku ini lahir dari pengalaman sehari-hari di kelas, saat mendampingi mahasiswa yang sering kali merasa “alergi” begitu mendengar kata *statistik*. Padahal, kalau dipahami dengan cara yang tepat, statistik bukan sesuatu yang menakutkan. Justru ia adalah alat yang sangat membantu kita untuk membaca, memahami, dan menjelaskan fenomena psikologi secara lebih objektif.

Dalam buku ini, kami mencoba menyajikan konsep-konsep statistik dengan bahasa yang sederhana, runtut, dan dekat dengan dunia psikologi. Setiap bab tidak hanya berisi teori, tetapi juga contoh nyata serta latihan soal yang bisa membantu pembaca melatih pemahaman. Harapannya, buku ini bisa menjadi jembatan agar mahasiswa lebih percaya diri ketika berhadapan dengan data penelitian.

Kami menyadari buku ini masih jauh dari sempurna. Kritik dan saran dari para pembaca tentu sangat kami nantikan, agar pada edisi-edisi berikutnya buku ini bisa semakin baik.

Akhir kata, semoga buku ini tidak hanya menjadi pegangan dalam belajar, tetapi juga menjadi sahabat yang menemani perjalanan Anda meneliti, menulis, dan memahami psikologi dengan lebih ilmiah.

Jakarta, Agustus 2025

Tim Penulis

Tentang Penulis

Dr. Sunu Bagaskara



adalah akademisi dan peneliti di bidang Psikologi dengan latar belakang pendidikan S1 hingga S3 di Fakultas Psikologi Universitas Indonesia. Ia berpengalaman mengajar Psikologi Sosial, Metode Penelitian Kuantitatif dan Statistik, serta Konstruksi Alat Ukur Psikologi. Minat penelitiannya mencakup kognisi sosial, psikologi lalu lintas, dan penerapan statistik dalam psikologi, dengan berbagai publikasi di jurnal ilmiah nasional dan internasional yang mencerminkan dedikasinya pada pengembangan ilmu psikologi dan keselamatan masyarakat.

Dr. Entin Nurhayati

berpengalaman mengajar kurang lebih selama 20 tahun. Pernah mengajar berbagai mata kuliah, seperti Faal, Psi Perkembangan, Psikodiagnosis (TAT/CAT, Rorschach) hingga beberapa tahun terakhir fokus di rumpun penelitian, khususnya mata kuliah metodologi penelitian dan statistik. Berdasar pengalaman mengajar ini serta membimbing penelitian mahasiswa, penulis memahami berbagai kesulitan yang dihadapi mahasiswa dalam memahami metopen dan statistik. Bersama sejawat, penulis berusaha melahirkan rangkaian buku praktis, agar mahasiswa dapat dengan mudah dan cepat memahami ilmu alat mengembangkan pengetahuan ini. Buku ini merupakan buku pertama yang dirancang untuk keperluan tersebut.

Sari Zakiah Akmal, Ph.D., Psikolog

adalah akademisi dan peneliti di bidang Psikologi Pendidikan. Ia lulusan dari program Sarjana dan Magister Profesi Psikologi Pendidikan, Fakultas Psikologi Universitas Indonesia dan program doktoral dari School of Applied Psychology, Griffith University, Australia. Sebagai dosen psikologi, ia pernah mengampu matakuliah terkait Metode Penelitian Kuantitatif, Statistik, Logika – Penulisan Ilmiah, Konstruksi Alat Ukur Psikologi, Asesmen Inteligensi, dan Pengembangan Diri dan Karier. Ia juga aktif dalam melakukan penelitian dan pengabdian masyarakat dengan fokus utama pada pengambilan keputusan karier, adaptabilitas karier, ketahanan akademik di kalangan mahasiswa, dan berbagai permasalahan terkait pendidikan siswa SMA/SMK dan mahasiswa di perguruan tinggi. Karya-karyanya telah dipublikasikan dalam berbagai jurnal akademik dan konferensi, mencerminkan komitmennya dalam mengembangkan penelitian dan pendidikan psikologi.

Titi Sahidah, Ph.D., Psikolog  

Aswin Januarsjaf, S.Psi., M.M 

adalah akademisi dan praktisi di bidang Psikologi serta Manajemen Sumber Daya Manusia. Lulusan Psikologi Universitas Padjadjaran dan Magister Manajemen PPM School of Management ini memiliki pengalaman lebih dari dua dekade di berbagai industri, khususnya dalam bidang rekrutmen, asesmen, dan pengembangan SDM. Ia mendirikan Talentlytica, sebuah platform asesmen berbasis data, serta aktif mengajar statistik psikologi dan melatih topik manajemen SDM di berbagai institusi. Karya-karya dan inovasi perangkat asesmennya mencerminkan komitmennya untuk menghubungkan ilmu psikologi dengan praktik manajemen modern di Indonesia.

Bagian I

PENGANTAR STATISTIK

Statistik memainkan peran yang sangat penting dalam dunia psikologi, khususnya dalam konteks penelitian dan pengambilan keputusan berbasis data. Bab-bab awal buku ini bertujuan memberikan pemahaman dasar tentang konsep-konsep statistik yang relevan bagi mahasiswa psikologi. Mulai dari sejarah dan definisi statistik, pembahasan ini menjelaskan bagaimana perkembangan ilmu ini dipengaruhi oleh berbagai tokoh dan kebutuhan untuk memahami variasi dalam kehidupan manusia. Selain itu, bab-bab ini juga menguraikan prinsip-prinsip dasar seperti hubungan antara sampel dan populasi, serta peran parameter dan statistik dalam menginterpretasikan data penelitian.

Lebih jauh, buku ini membahas pentingnya statistik dalam penelitian psikologi, terutama untuk mengakomodasi kompleksitas perilaku manusia. Dengan menggunakan pendekatan deskriptif dan inferensial, statistik membantu peneliti menggambarkan data secara efektif sekaligus membuat generalisasi yang valid dari sampel ke populasi. Bab-bab ini dirancang untuk menjadi landasan kokoh bagi mahasiswa dalam memahami bagaimana statistik dapat digunakan untuk menjawab berbagai pertanyaan penelitian, mengatasi tantangan analisis data, dan mendukung validitas ilmiah psikologi sebagai disiplin ilmu.

Tujuan Pembelajaran

Bab 1. Pengertian & Sejarah Ringkas Statistik:

- Memahami definisi statistik dan konsep dasar yang meliputi parameter dan statistik.
- Mengidentifikasi hubungan antara sampel dan populasi dalam konteks penelitian.
- Memahami peran statistik sebagai alat untuk mengorganisasi, merangkum, dan menginterpretasi informasi.

Bab 2. Statistik dalam Penelitian Psikologi:

- Menjelaskan peran statistik dalam mendukung psikologi sebagai ilmu ilmiah.
- Mengevaluasi signifikansi statistik dalam memahami variasi perilaku dan membuat inferensi dari data penelitian.

Bab 3. Jenis-jenis Statistik: Deskriptif & Inferensial:

- Mengidentifikasi perbedaan utama antara statistik deskriptif dan statistik inferensial, termasuk ruang lingkup dan tujuan keduanya.
- Memahami bagaimana kombinasi statistik deskriptif dan inferensial mendukung analisis data yang kuat, khususnya dalam ilmu perilaku dan sosial.

Bab 1

Pengertian & Sejarah Ringkas Statistik

Sejarah statistik bermula dari kebutuhan memahami **variasi dalam ilmu hayati** dan sosial (Gravetter & Wallnau, 2017). Variasi ini menjadi pusat perhatian dengan diperkenalkannya teori evolusi oleh Charles Darwin pada abad ke-19. Pionir seperti Francis Galton, sepupu Darwin, berusaha menguantifikasi pewarisan sifat biologis dan memunculkan **konsep regresi terhadap rata-rata**. Galton juga mengembangkan metode **korelasi**, yang menjadi dasar statistik modern. Selanjutnya, Karl Pearson memperkuat landasan matematis statistik dengan memperkenalkan koefisien korelasi dan uji chi-kuadrat. Perkembangan ini melibatkan kajian biometrika dan genetika, dengan fokus pada pewarisan sifat yang dipengaruhi oleh gerakan eugenika.

Pada abad ke-20, Ronald Fisher memperkenalkan **analisis varians** dan **metode eksperimental** untuk memperluas penerapan statistik, terutama dalam ilmu perilaku (Cowles, 2000). Fisher, bersama Pearson, menekankan pentingnya inferensi statistik untuk mengatasi variasi alami. Pada saat yang sama, probabilitas berkembang sebagai dasar teoretis statistik, berakar dari upaya menjawab masalah dunia nyata seperti perjudian dan prediksi aktuarial. Normalisasi distribusi data, yang diperkenalkan oleh Lambert Quetelet, menjadi inti statistik inferensial. Hingga kini, statistik terus berkembang dengan mengintegrasikan metode baru untuk menjawab tantangan dalam berbagai disiplin ilmu.

1.1 Definisi Statistik

Statistik adalah **kumpulan prosedur matematis** yang digunakan untuk **mengorganisasi, merangkum, dan menginterpretasi** informasi (Gravetter & Wallnau, 2017). Dalam konteks penelitian, statistik membantu para peneliti untuk memahami hasil studi dan menyampaikan informasi tersebut secara akurat dan informatif. Statistik juga menyediakan teknik-teknik standar yang diakui dalam komunitas ilmiah sehingga hasil analisis dapat diinterpretasikan dengan konsistensi yang tinggi oleh peneliti lainnya.

1.2 Sampel dan Populasi

Populasi adalah **keseluruhan individu** atau elemen yang menjadi fokus penelitian. Karena populasi biasanya terlalu besar untuk dianalisis secara langsung, peneliti memilih **sampel**, yaitu **sekelompok individu yang mewakili populasi**. Sampel bertujuan

untuk menyederhanakan penelitian sambil tetap memungkinkan penarikan kesimpulan yang dapat digeneralisasi ke populasi. Hubungan antara sampel dan populasi bersifat dua arah: sampel diambil dari populasi, dan hasil penelitian pada sampel digeneralisasikan kembali ke populasi.

1.3 Parameter dan Statistik

Parameter adalah nilai yang menggambarkan suatu **karakteristik dari populasi**, seperti rata-rata populasi, sedangkan statistik adalah nilai yang menggambarkan karakteristik dari sampel, seperti rata-rata sampel. Dalam penelitian, data yang diperoleh berasal dari sampel, sehingga **statistik** digunakan untuk **memperkirakan parameter populasi**. Proses ini menciptakan hubungan erat antara statistik sampel dan parameter populasi, yang menjadi dasar dari banyak prosedur statistik.

Bab 2

Statistik dalam Penelitian Psikologi

Statistik memegang peran penting dalam perkembangan ilmu psikologi, khususnya dalam upaya menjadikannya **ilmu yang lebih ilmiah** (Dancey & Reidy, 2017). Dimulai dengan prinsip **determinisme** yang mengasumsikan adanya **keteraturan dalam alam**, psikologi mencoba meniru pendekatan ilmu alam untuk memprediksi dan mengontrol perilaku. Hal ini dipopulerkan oleh tokoh seperti John B. Watson melalui **behaviorisme** yang mengedepankan studi eksperimental untuk mengendalikan variabel-variabel perilaku. Namun, pendekatan **deterministik** ini dipadukan dengan model **probabilistik** untuk mengakomodasi kompleksitas dan variasi yang melekat pada manusia.

Statistik memungkinkan psikologi menangani variasi data dan membuat **inferensi** dari sampel ke populasi. Misalnya, Ronald Fisher mengembangkan desain eksperimen dan analisis varians (**ANOVA**) untuk membantu peneliti memahami **hubungan sebab-akibat** meskipun terdapat variabilitas. Selain itu, pengembangan metode korelasi oleh Francis Galton dan Karl Pearson membantu mengukur **hubungan antar variabel**, sementara analisis faktor yang diperkenalkan Charles Spearman mengidentifikasi faktor-faktor dalam kecerdasan (Coolican, 2014).

Dalam sejarahnya, statistik tidak hanya digunakan untuk menganalisis data, tetapi juga sebagai **alat eksplorasi**. Contohnya, metode **analisis faktor** sering digunakan untuk memetakan domain baru dalam psikologi sebelum eksperimen langsung dilakukan. Statistik juga membantu memperjelas perbedaan antara pendekatan eksperimental yang berfokus pada manipulasi variabel independen dan pendekatan korelasional yang mempelajari hubungan antar variabel dalam kondisi alami.

Signifikansi statistik dalam psikologi tidak lepas dari pengaruh pionir seperti Gustav Fechner, yang memulai pendekatan kuantitatif untuk mengukur hubungan antara stimulus dan sensasi. Meskipun beberapa konsep awal seperti hukum psikofisik Fechner kini telah direvisi, kontribusinya mendasari metode eksperimental modern. Statistik memungkinkan peneliti psikologi untuk mengatasi tantangan dalam memahami kondisi manusia yang penuh variasi, sekaligus menyediakan dasar untuk menguji hipotesis secara objektif (Salsburg, 2002).

Statistik juga memperkuat nilai-nilai keilmiah psikologi, seperti keterbukaan terhadap koreksi, validasi empiris, dan kemampuan untuk memprediksi. Dengan demikian, statistik tidak hanya menjadi alat teknis tetapi juga **kerangka filosofis** yang mendukung psikologi sebagai ilmu yang dapat menjembatani antara determinisme dan kebebasan manusia, serta antara pandangan **positivistik** dan **humanisme**.

Bab 3

Jenis-jenis Statistik: Deskriptif & Inferensial

Statistik dapat dibagi menjadi dua kategori utama, yaitu **statistik deskriptif** dan **statistik inferensial**, yang masing-masing memiliki peran penting dalam analisis data. Statistik deskriptif (**Bagian 3**) digunakan untuk **merangkum, mengorganisasi, dan menyederhanakan data** mentah menjadi informasi yang lebih mudah dipahami. Teknik-teknik ini termasuk distribusi frekuensi, tabel, grafik, rata-rata (*mean*), median, mode, serta ukuran dispersi seperti variansi dan standar deviasi. Statistik deskriptif membantu memberikan gambaran umum tentang data tanpa membuat kesimpulan lebih luas.

Sebaliknya, statistik inferensial (**Bagian 4**) digunakan untuk membuat **generalisasi tentang populasi** berdasarkan data sampel. Teknik ini melibatkan analisis data dari sampel untuk menjawab pertanyaan penelitian dan menyimpulkan parameter populasi. Statistik inferensial sering menggunakan konsep probabilitas untuk memperkirakan sejauh mana kesimpulan dari sampel dapat mewakili populasi secara keseluruhan. Contoh aplikasinya termasuk uji hipotesis, analisis varians (**ANOVA**), dan regresi.

Perbedaan utama antara keduanya terletak pada tujuan dan ruang lingkupnya. Statistik deskriptif fokus pada **penggambaran data** yang ada, sedangkan statistik inferensial fokus pada **pengambilan keputusan atau prediksi** berdasarkan data tersebut. Misalnya, statistik deskriptif digunakan untuk menghitung rata-rata usia partisipan dalam sebuah survei, sementara statistik inferensial menggunakan data tersebut untuk memprediksi rata-rata usia seluruh populasi.

Dalam praktiknya, kedua jenis statistik ini **saling melengkapi**. Statistik deskriptif menyediakan dasar untuk memahami data, sedangkan statistik inferensial memberikan kerangka untuk mengambil keputusan yang lebih luas. Sebagai contoh, analisis distribusi frekuensi dalam statistik deskriptif dapat menjadi langkah awal sebelum melakukan uji-t atau **ANOVA** dalam statistik inferensial.

Kombinasi kedua pendekatan ini mendukung analisis data yang kuat, terutama dalam ilmu perilaku dan sosial. Statistik deskriptif membantu menggambarkan data dengan jelas, sementara statistik inferensial memberikan justifikasi yang didukung oleh probabilitas untuk menjawab pertanyaan-pertanyaan penelitian yang kompleks. Hal ini menjadikan statistik alat yang tak tergantikan dalam proses penelitian ilmiah.

Soal Latihan

Penilaian mengenai hasil belajar merupakan bagian penting dalam sebuah proses pembelajaran. Ujilah pengetahuan dan pemahaman Anda mengenai materi Bab 1 ini dengan menjawab sejumlah pertanyaan pada link di bawah ini:



Scan QR untuk membuka versi interaktif: <https://www.yarsi.ac.id/fakultas-psikologi/bukustatistik/latihan1/>

Bagian II

PERSIAPAN DATA

Bab ini akan membahas mengenai mengenali dan mempersiapkan data penelitian agar dapat diolah lebih lanjut secara statistik. Untuk menghasilkan analisis yang valid dan bermakna, peneliti perlu memahami jenis data yang dimiliki, melakukan proses pembersihan data secara sistematis, serta menjaga akuntabilitas dalam setiap tahap pengelolaan data. Tahapan ini bukan sekadar teknis, melainkan fondasi penting untuk memastikan bahwa hasil analisis benar-benar mencerminkan realitas yang diteliti.

Bab ini diawali dengan penjelasan tentang jenis data, termasuk cara mengidentifikasi tipe data serta prinsip dalam penamaan dan pengkodean variabel agar konsisten dan mudah diinterpretasikan. Selanjutnya, pembahasan berlanjut pada proses pembersihan data, yang mencakup analisis deskriptif awal, penanganan missing value, serta deteksi pencilan (*outlier*) yang dapat memengaruhi hasil analisis. Terakhir, bab ini menekankan pentingnya akuntabilitas data, yaitu tanggung jawab peneliti untuk mendokumentasikan, menyimpan, dan mengelola data secara transparan agar dapat dipertanggungjawabkan secara ilmiah. Dengan memahami dan menerapkan ketiga aspek ini, mahasiswa akan memiliki dasar yang kuat dalam mempersiapkan data untuk analisis statistik yang sah dan terpercaya.

Tujuan Pembelajaran

Bab 4. Jenis Data:

- Mengidentifikasi berbagai jenis data dalam konteks penelitian psikologi (nominal, ordinal, interval, rasio).
- Menerapkan prinsip penamaan dan pengkodean variabel secara konsisten dan sistematis.
- Memahami pentingnya kesesuaian antara jenis data dan teknik analisis statistik yang akan digunakan.

Bab 5. Pembersihan Data:

- Melakukan analisis deskriptif awal untuk mengevaluasi distribusi dan karakteristik dasar data.
- Mengidentifikasi dan menangani data hilang (*missing value*) serta *outlier* secara tepat untuk memastikan keakuratan analisis lanjutan.

Bab 6. Akuntabilitas Data:

- Menjelaskan pentingnya pencatatan proses analisis statistik sebagai bentuk akuntabilitas ilmiah.
- Memahami pentingnya transparansi dalam meningkatkan kualitas dan integritas penelitian psikologi.

Bab 4

Jenis Data

Sebelum data dianalisis, peneliti perlu memahami terlebih dahulu **jenis data** yang dimiliki. Pengklasifikasian data menjadi **nominal**, **ordinal**, **interval**, atau **rasio** akan menentukan teknik statistik apa yang tepat untuk digunakan. Selain itu, proses penamaan dan pengkodean variabel juga merupakan bagian penting dalam pengelolaan data yang baik. **Pengkodean yang konsisten** akan memudahkan dalam proses input data, analisis, maupun interpretasi hasil. Oleh karena itu, pengenalan jenis data dan cara mengelola variabel adalah fondasi penting sebelum melangkah ke tahap analisis statistik.

4.1 Mengidentifikasi Jenis Data

Data adalah kumpulan informasi berupa angka. Informasi ini biasanya dicatat sesuai dengan definisi yang diinginkan oleh peneliti. Sebagai contoh, data tinggi badan dicatat dalam centimeter per individu untuk anak-anak usia 0-10 tahun di Indonesia. Pada data tersebut terdapat data tinggi badan anak yang dapat diolah per individu. Di saat yang sama, terdapat pula kelompok data yang lebih besar, misalnya data tinggi badan untuk wilayah DKI Jakarta, Jawa Barat, dan wilayah lainnya yang kemudian dapat diolah dan dibandingkan per wilayah.

Data disebut dengan *raw score* (**data mentah**) apabila data tersebut adalah data langsung dari partisipan, tidak dimodifikasi, dan tidak dikonversi ke dalam nilai tertentu. Contoh data mentah:

ID Partisipan	Skor Mentah Matematika (jumlah menjawab benar dari 50 soal)	Skor Konversi dalam rentang 0-100 (<i>raw</i> /50 x 100)
1	25	50
2	35	70
3	45	90
4	15	30
5	37	74

Data dapat memberikan berbagai jenis informasi yang berbeda. Misalnya, informasi dasar seperti jenis kelamin, atau informasi lainnya yang lebih rumit seperti sikap atau perasaan seseorang. Terdapat berbagai jenis data di dalam penelitian psikologi, yaitu:

1. Data kategorikal atau nominal

Data kategorikal atau nominal adalah penunjuk **karakteristik**, **label**, atau **golongan** pada subjek. Sebagai contoh: jenis kelamin (laki-laki dan perempuan), daerah tempat tinggal (Jakarta, Bekasi, Bogor) dan lain sebagainya. Pemberian kode pada data-data ini hanya bersifat *dummy* dan tidak memiliki makna apa-apa secara statistik.

2. Data ordinal

Sebagai contoh, pada sebuah data penelitian, laki-laki diberikan kode 0 dan perempuan kode 1. Hal ini tidak berarti perempuan memiliki nilai yang lebih tinggi daripada laki-laki,

begitu pula sebaliknya. Pemberian kode ini hanya untuk kemudahan pengolahan data dan tidak berarti secara statistik. Misalnya pada jenis kelamin, nilai rata-rata (*mean*) tidak dapat dihitung meski laki-laki disematkan angka 0 dan perempuan disematkan angka 1.

3. Data interval

Data interval adalah data yang memiliki makna, terdapat **informasi mengenai jarak** antara satu skor dengan skor lainnya namun tidak ada informasi mengenai seberapa mutlak nilai tersebut karena **titik 0 tidak definitif**. Misalnya suhu udara 0° Celsius tidak berarti 'tidak ada temperatur'. Titik tersebut adalah definisi dari kondisi di mana air membeku. Perbedaan suhu antara 30°C dan 20°C adalah 10°C . Namun, tidak dapat dikatakan bahwa 20°C adalah dua kali lebih panas daripada 10°C karena suhu tidak memiliki titik 0°C yang definitif.

4. Data rasio

Data rasio adalah data yang memiliki **titik 0 yang mutlak** sehingga jarak antara satu skor dengan skor lainnya dapat dilakukan secara definitif. Sebagai contoh, berat badan 100 kilogram dapat dikatakan lebih berat dua kali lipat dibandingkan seseorang dengan berat badan 50 kg.

4.2 Penamaan dan Pengkodean Data/Variabel

Langkah awal yang penting dalam mempersiapkan data adalah **memberikan nama atau kode variabel** dengan jelas, mudah dipahami, dan mengikuti pola penamaan yang konsisten. Penamaan variabel yang baik tidak hanya memudahkan peneliti dalam mengolah data, tetapi juga memastikan bahwa **data dapat dipahami dan digunakan** kembali oleh peneliti lain, terutama ketika bekerja dengan data set yang besar atau di dalam tim.

Sebagai contoh, dalam sebuah penelitian yang melibatkan tiga kali pengambilan data menggunakan dua kuesioner – EQ-5D dan PedsQL – penamaan variabel dapat menggunakan kode yang menggambarkan waktu pengambilan data dan jenis instrumen secara ringkas dan jelas. Misalnya:

- Data pengambilan pertama diberi kode B (*Baseline*)
- Pengambilan kedua diberi kode R (*Retest*),
- Dan pengambilan ketiga diberi kode F (*Follow-up*).

Selanjutnya, nama variabel dibentuk dengan menggabungkan kode waktu dan nama instrumen. Dengan demikian:

- Untuk pengambilan pertama dengan EQ-5D, variabel dinamai BEQ5D, dan untuk PedsQL dinamai BPedsQL.
- Untuk pengambilan kedua: REQ5D dan RPedsQL.
- Dan seterusnya untuk pengambilan ketiga.

Pola penamaan yang konsisten seperti ini akan mempermudah proses analisis, mengurangi risiko kesalahan, serta meningkatkan transparansi dan akuntabilitas, khususnya jika pengolahan data dilakukan oleh pihak lain atau pada proyek penelitian berskala besar.

Bab 5

Pembersihan Data

Setelah data dikumpulkan dan diklasifikasikan, langkah selanjutnya adalah memastikan data tersebut layak untuk dianalisis. Proses ini dikenal sebagai **data cleaning** atau pembersihan data. Dalam tahap ini, peneliti melakukan **analisis deskriptif awal** untuk mendapatkan gambaran umum data, serta mengecek kemungkinan adanya **missing value** atau **outlier** yang dapat memengaruhi hasil analisis. Pembersihan data bukan hanya soal menghapus skor-skor yang tidak wajar, tetapi juga tentang membuat keputusan yang tepat berdasarkan konteks penelitian. Dengan data yang bersih, hasil analisis akan menjadi lebih **akurat dan dapat dipercaya**.

5.1 Melakukan Analisis Deskriptif

Setelah peneliti memberi nama variabel dan mengidentifikasi jenis data sesuai dengan sifat masing-masing variabel, langkah berikutnya adalah melakukan analisis deskriptif awal terhadap data. Analisis deskriptif ini bertujuan untuk memastikan kualitas data sebelum masuk ke tahap analisis lebih lanjut.

Beberapa hal penting yang perlu diperhatikan dalam tahap ini antara lain:

- **Memeriksa sebaran skor**

Peneliti perlu melihat apakah nilai total skor, minimum, maksimum, rata-rata (*mean*), dan simpangan baku (standar deviasi) dari setiap variabel berada dalam rentang yang sesuai dengan instrumen alat ukur dan sampel yang diteliti. Hal ini membantu mendeteksi adanya kesalahan input data atau anomali yang tidak sesuai dengan ekspektasi.

- **Memeriksa data hilang (*missing values*)**

Identifikasi jumlah dan pola *missing values* pada setiap variabel sangat penting, karena dapat mempengaruhi validitas hasil analisis.

- **Mendeteksi nilai pencilan (*outliers*)**

Nilai-nilai pencilan dapat mengindikasikan kesalahan pencatatan data atau variasi yang ekstrem di dalam sampel. Oleh karena itu, penting untuk mengidentifikasi *outlier* pada tahap awal, kemudian menentukan apakah nilai tersebut merupakan bagian dari variasi alami atau justru kesalahan yang perlu diperbaiki atau dikeluarkan dari analisis.

Dengan melakukan analisis deskriptif ini secara teliti, peneliti dapat memastikan bahwa data yang akan dianalisis lebih lanjut sudah bersih, valid, dan siap untuk digunakan, sehingga hasil penelitian menjadi lebih akurat dan dapat dipertanggungjawabkan.

5.2 Data Hilang

Terdapat sejumlah hal yang perlu Anda lakukan sebelum memulai analisis utama terhadap data Anda. Hal pertama adalah memeriksa apakah terdapat **missing data** (data hilang). Data hilang terjadi ketika terdapat pernyataan yang tidak diisi oleh seseorang yang menjawab survei atau

kuesioner Anda. Partisipan mungkin tidak menjawab salah satu item pada survei karena berbagai alasan. Mereka mungkin melewatkan sebuah pertanyaan, enggan menjawab pertanyaan tertentu, atau merasa bosan dan berhenti mengisi survei. Ketidaklengkapan jawaban pada satu atau beberapa item ini menimbulkan masalah dalam analisis.

Data hilang dapat dikategorikan menjadi (1) *missing completely at random* (MCAR), (2) *missing at random* (MAR), atau (3) *missing not at random* (MNAR) (Buuren, 2018).

1. **Missing completely at random (MCAR)** berarti probabilitas sebuah data hilang sama besar untuk semua responden. Misalnya, seseorang secara acak melewatkan satu pertanyaan di survei Anda, sehingga data hilang itu benar-benar acak.
2. Jika probabilitas sebuah nilai hilang hanya sama dalam kelompok-kelompok tertentu yang didefinisikan oleh data yang teramati, maka data tersebut disebut **missing at random (MAR)**. Karena itu, MCAR dan MAR adalah konsep yang saling terkait. Sebagai contoh, ditemukan bahwa responden yang tingkat stresnya tinggi cenderung melewatkan pertanyaan tentang tidur, mungkin karena merasa pertanyaan tersebut terlalu sensitif atau tidak relevan bagi mereka dalam kondisi stres.
3. Jika data hilang tidak memenuhi asumsi MCAR maupun MAR, maka disebut **missing not at random (MNAR)**. Sebagai contoh, jika sejumlah besar peserta sengaja melewati satu pertanyaan tertentu pada survei, maka hal itu tidak terjadi secara acak. Kemungkinan ada alasan tertentu mengapa pertanyaan itu dilewati, misalnya karena pertanyaan kurang jelas, terlalu pribadi, atau tersembunyi di bagian bawah halaman.

Terdapat sebuah uji untuk mengetahui apakah data hilang secara acak atau tidak, yaitu *Little's MCAR test*. Secara sederhana, jika hasil uji tidak signifikan, maka data hilang kemungkinan terjadi secara acak. Sebaliknya, jika hasil uji signifikan, ada kemungkinan data hilang karena alasan sistematis atau tidak acak.

Lalu, apa yang bisa dilakukan peneliti untuk menangani data hilang? Secara umum, terdapat dua cara utama untuk menangani data hilang, yaitu:

1. **Penggantian dengan rata-rata (*mean replacement*)**. Dalam prosedur ini, Anda mengganti titik data yang hilang dengan nilai rata-rata variabel tersebut. Namun, teknik ini hanya disarankan jika data hilang secara acak (*at random*) dan proporsinya kurang dari 5% pada variabel yang bersangkutan.
2. **Imputasi majemuk (*multiple imputation*)**. Teknik ini dilakukan dengan bantuan program statistik yang Anda gunakan, yang menganalisis pola data dan menetapkan nilai untuk variabel yang hilang pada kasus tertentu. Nilai ini didasarkan pada jawaban sebelumnya pada variabel terkait, serta jawaban tidak hilang pada variabel tersebut di kasus lain. Disarankan menggunakan metode ini jika data hilang secara acak dengan proporsi antara 5–10% dari total respons pada variabel tersebut.


5.3 Data Pencilan

Salah satu hal yang perlu diperhatikan saat menganalisis data adalah pengaruh *outlier* — yaitu data yang nilainya sangat tinggi atau sangat rendah dibandingkan data lainnya — terhadap hasil keseluruhan. Contohnya, jika Anda bertanya kepada orang-orang tentang berapa cangkir kopi yang mereka minum dalam sehari, sebagian besar jawabannya mungkin berkisar antara nol hingga empat cangkir. Sebaran ini disebut dengan sebaran jawaban yang normal. Namun, jika ada satu orang yang menjawab bahwa ia minum **17 cangkir kopi sehari**, maka jawaban ini bisa dianggap sebagai *outlier* bila dibandingkan dengan partisipan lainnya.

Kita bisa mengasumsikan bahwa orang tersebut memang memiliki masalah dengan kafein atau mungkin salah memasukkan jawaban. Apa pun alasannya, jawaban ini bisa meningkatkan rata-rata (*mean*) konsumsi kopi dalam sampel, padahal sebetulnya jawaban ini tidak mewakili kebiasaan rata-rata peminum kopi.

Ada beberapa cara secara statistik untuk mengidentifikasi *outlier* dalam kumpulan data Anda (Tabachnick & Fidell, 2014):

1. Mengubah jawaban peserta untuk setiap variabel menjadi skor-z (*z-score*).
Skor-z adalah transformasi dasar untuk membandingkan jawaban peserta dengan distribusi standar yang memiliki rata-rata 0 dan standar deviasi 1.
Jika suatu jawaban memiliki skor-z lebih besar dari +3.3 atau kurang dari -3.3, maka jawaban ini dianggap sebagai *outlier*.
2. Memvisualisasikan data menggunakan *box plot* atau *bar graph*, lalu melihat secara langsung apakah ada data yang tampak menyimpang jauh. Lihat Gambar 5.1 untuk visualisasi dari *outlier* menggunakan *box plot*.



Gambar 5.1: Outlier dalam boxplot

Setelah menemukan *outlier*, Anda punya dua pilihan (Dancey & Reidy, 2017):

1. **Tetap menyertakan** dalam analisis jika Anda menganggap *outlier* ini bukan kebetulan.
2. **Menghapus** dari analisis jika *outlier* ini muncul karena alasan yang tidak valid, misalnya kesalahan input atau jawaban yang tidak realistis.

Jika jawaban *outlier* tersebut tidak masuk akal dalam konteks pertanyaan, atau terlalu ekstrem tanpa alasan yang jelas, maka sebaiknya dianggap sebagai jawaban tidak valid (*spurious response*) dan dihapus dari analisis. Namun, jika jawaban tersebut masih masuk akal atau hanya sedikit melampaui batas skor-z (± 3.3), Anda bisa mempertimbangkannya sebagai *outlier* yang valid dan tetap menyertakannya dalam analisis.

Bab 6

Akuntabilitas Data

Salah satu langkah penting yang sering kali terabaikan dalam pengolahan data statistik adalah **mencatat secara sistematis** setiap proses analisis yang dilakukan. Pencatatan ini merupakan inti dari prinsip **akuntabilitas**, yaitu kemampuan untuk mempertanggungjawabkan seluruh proses analisis kepada diri sendiri maupun komunitas ilmiah (Gelfond dkk., 2014). Dengan memiliki catatan lengkap, peneliti lain dapat menelusuri, memverifikasi, atau mereplikasi prosedur yang telah dilakukan, sehingga penelitian menjadi lebih transparan dan dapat dipercaya.

Pentingnya akuntabilitas semakin terasa ketika terjadi hasil yang tidak sesuai harapan atau tampak tidak wajar. Dalam situasi ini, dokumentasi proses analisis akan sangat membantu peneliti untuk menelusuri kembali langkah-langkah yang telah diambil, **mengidentifikasi potensi kesalahan** (seperti pengkodean yang keliru, pemilihan teknik analisis yang tidak tepat, atau salah input data), dan memperbaikinya tanpa harus mengulang seluruh proses dari awal.

Pencatatan proses analisis dapat dilakukan melalui *script* atau *syntax* di perangkat lunak statistik. *Tools* ini memungkinkan setiap langkah (misalnya transformasi variabel dan *filtering* data) untuk terekam secara otomatis dan dapat dijalankan ulang. Penggunaan *syntax* bukan hanya efisien, tetapi juga menciptakan **audit trail** yang sangat berguna dalam kerja tim atau revisi laporan.

Jika perangkat lunak yang digunakan tidak menyimpan jejak analisis secara otomatis, maka **pencatatan manual** menjadi penting. Hal ini bisa dilakukan dengan menuliskan setiap prosedur analisis dalam dokumen pendamping, seperti di *Microsoft Word*, *Google Docs*, atau aplikasi pencatat lain. Format catatan sebaiknya mencakup: nama *file* data, langkah-langkah analisis yang dilakukan, alasan memilih teknik tertentu, serta ringkasan hasil yang diperoleh.

Menjaga akuntabilitas bukan hanya menunjukkan **profesionalisme** peneliti, tetapi juga mendukung prinsip replikasi, transparansi, dan validitas ilmiah. Dokumentasi proses analisis dianggap sebagai bagian dari etika penelitian, terutama di era *open science*. Oleh karena itu, mahasiswa perlu membiasakan diri untuk tidak hanya fokus pada hasil akhir, tetapi juga menaruh perhatian serius pada proses yang ditempuh untuk sampai ke hasil tersebut.

Soal Latihan

Penilaian mengenai hasil belajar merupakan bagian penting dalam sebuah proses pembelajaran. Ujilah pengetahuan dan pemahaman Anda mengenai materi Bab 1 ini dengan menjawab sejumlah pertanyaan pada link di bawah ini:



Scan QR untuk membuka versi interaktif: <https://www.yarsi.ac.id/fakultas-psikologi/bukustatistik/latihan2/>

Bagian III

STATISTIK DESKRIPTIF

Setelah data dikumpulkan dan dipersiapkan, langkah selanjutnya dalam proses analisis adalah memahami karakteristik umum dari data tersebut. Bab ini membahas tentang statistik deskriptif, yaitu serangkaian teknik yang digunakan untuk merangkum, menyederhanakan, dan menyajikan data mentah menjadi informasi yang lebih mudah dipahami. Statistik deskriptif tidak berfokus pada pengambilan keputusan atau generalisasi, melainkan pada penggambaran pola, kecenderungan, dan sebaran data yang ada.

Bab ini terdiri dari tiga bagian utama. Pertama, pembahasan mengenai ukuran pemusatan data (*central tendency*), mencakup *mean* (rata-rata), median, dan modus yang menggambarkan nilai pusat dari sekumpulan data. Kedua, penjelasan tentang sebaran data (dispersi) yang mencakup rentang, varians, dan standar deviasi untuk memahami seberapa jauh data menyebar dari pusatnya. Terakhir, akan dibahas mengenai bentuk distribusi data, termasuk konsep simetri, *skewness*, dan *kurtosis*, yang penting untuk mengetahui apakah data berdistribusi normal atau memiliki penyimpangan tertentu.

Bab 7

Ukuran Pemusatan Data

Bayangkan, Anda sedang melakukan pengamatan terhadap hasil belajar di satu sekolah, misalnya pelajaran matematika dari 150 anak kelas X. Dari daftar nilai itu, Anda mempunyai informasi mengenai nilai dari setiap anak. Namun, bagaimana Anda akan mengatakan kepada khalayak, mengenai capaian nilai matematika dari ke-150 anak ini? Seberapa baik capaian tersebut? Untuk menjawabnya, Anda memerlukan satu **perwakilan angka** yang dapat dinilai sebagai baik, cukup atau buruk. Inilah yang disebut dengan konsep **central tendency** atau ukuran pemusatan data, yaitu satu angka yang menjadi ukuran sentral dari semua kumpulan angka yang diwakilinya. Terdapat tiga macam ukuran sentral, yaitu **mean**, median dan modus.

7.1 Mean

Mean (rerata) merupakan ukuran tendensi sentral yang paling umum digunakan karena mempertimbangkan semua nilai dalam distribusi. **Mean** diperoleh dengan cara menjumlahkan seluruh nilai data dibagi dengan banyaknya data. **Mean** sangat sensitif terhadap nilai ekstrem (**outlier**) yang dapat memengaruhi hasilnya secara signifikan.

Misalnya kita memperoleh data dari 10 orang seperti di bawah ini:

4	4	6	6	7	4	7	3	5	4
---	---	---	---	---	---	---	---	---	---

Setiap angka menggambarkan skor dari setiap orang. Berikut adalah cara menghitung **mean** dari data tersebut:

$$\text{Mean} = \frac{\sum x}{n} = \frac{4 + 4 + 6 + 6 + 7 + 4 + 7 + 3 + 5 + 4}{10} = \frac{50}{10} = 5$$

7.2 Median

Median adalah **nilai tengah** dari data yang telah diurutkan dari yang terkecil ke terbesar. Jika jumlah data ganjil, median adalah nilai di posisi tengah; jika genap, median adalah rata-rata dari dua nilai tengah. Median berguna ketika data mengandung pencilan atau distribusinya tidak simetris, karena tidak terpengaruh oleh nilai-nilai ekstrem.

Menggunakan data yang sama dengan yang di atas, maka untuk memperoleh nilai median kita perlu mengurutkan data dari yang paling kecil hingga yang paling besar. Nilai median merupakan nilai yang ada di tengah dari urutan data tersebut. Sehingga, dari data tersebut, dapat ditentukan bahwa nilai median adalah sebagai berikut:

3	4	4	4	4	5	6	6	7	7
---	---	---	---	---	---	---	---	---	---

Mengingat jumlah data yang diperoleh genap (10), maka nilai median dihitung dengan menghitung rata-rata dari dua nilai yang berada di tengah. Dalam hal ini, maka median dari data adalah:

$$\text{Median} = \frac{4 + 5}{2} = 4.5$$

7.3 Modus

Modus adalah nilai yang **paling sering** muncul dalam suatu kumpulan data. Tidak seperti *mean* dan median, modus bisa digunakan pada data kategorikal dan dapat memiliki lebih dari satu nilai (bimodal atau multimodal). Modus cocok digunakan untuk mengidentifikasi nilai yang paling umum dalam suatu populasi atau kelompok.

Langkah penting untuk memperoleh nilai modus dalam kelompok data adalah dengan membuat tabel **distribusi frekuensi**. Tabel ini berfungsi untuk mengidentifikasi nilai, skor, atau data apa yang paling sering muncul (frekuensi tertinggi). Masih menggunakan data yang sama dengan yang di atas, perlu dibuat tabel distribusi frekuensi sebagai berikut:

Nilai	Frekuensi
3	1
4	4
5	1
6	2
7	2

Berdasarkan pengelompokan data berdasarkan frekuensi kemunculannya yang ditampilkan pada tabel Distribusi frekuensi tersebut, maka kita dapat menentukan bahwa nilai Modus dari data adalah 4.

Bab 8

Ukuran Penyebaran Data

Setelah mengetahui nilai pusat dari suatu data melalui ukuran pemusatan data, langkah berikutnya adalah memahami seberapa jauh data menyebar dari nilai pusat tersebut. **Ukuran penyebaran data**, atau **dispersi**, memberikan informasi penting tentang variasi atau keragaman dalam kumpulan data. Dua set data bisa memiliki *mean* yang sama, tetapi penyebarannya bisa sangat berbeda, dan perbedaan ini dapat memengaruhi cara interpretasi data secara keseluruhan. Dalam sub-bab ini, akan dibahas beberapa ukuran utama penyebaran, yaitu rentang (*range*), standar deviasi, dan varians, yang membantu menggambarkan tingkat homogenitas atau heterogenitas suatu data secara lebih mendalam.

8.1 *Range*

Range, atau rentang data, adalah selisih antara nilai tertinggi dengan nilai terendah dalam sebuah set data. **Range** menunjukkan seberapa **lebar sebaran nilai** dalam data, namun karena hanya mempertimbangkan dua nilai ekstrem, ukuran ini sangat sensitif terhadap *outlier* dan tidak menggambarkan variasi data secara keseluruhan. Meskipun demikian, **range** tetap berguna sebagai gambaran awal tentang sebaran data.

Untuk dapat memahami fungsi **range** dalam memahami set data, mari kita pelajari kasus berikut ini. Misalnya, seorang peneliti memiliki data nilai tugas mata pelajaran Matematika dari 3 kelas yang berbeda:

Kelas A	4	4	6	6	7	4	7	3	5	4
Kelas B	2	6	6	7	7	8	4	4	3	3
Kelas C	6	5	6	4	5	6	4	4	5	5

Pertanyaan penting mengenai data tersebut adalah apakah ketiga kelas tersebut memperoleh capaian belajar yang sama. Jika hanya mengandalkan nilai rata-rata, maka ketiga kelas tersebut akan tampak sama karena memiliki nilai rata-rata yang sama, yaitu 5. Padahal jika dilihat ke perolehan nilai individual, terlihat berbeda. Nilai **range** pada data dapat membantu kita untuk menggambarkan seberapa berbeda dan bervariasi data yang dimiliki dan makna variasi tersebut dalam memahami setiap poin data. Untuk itu, kita perlu menghitung selisih skor terbesar dengan skor terkecil untuk setiap data kelas.

$$\text{Range kelas A} = \text{nilai tertinggi} - \text{nilai terendah} = 7 - 3 = 4$$

$$\text{Range kelas B} = \text{nilai tertinggi} - \text{nilai terendah} = 8 - 2 = 6$$

$$\text{Range kelas C} = \text{nilai tertinggi} - \text{nilai terendah} = 6 - 2 = 4$$

Dari hasil penghitungan, dapat dilihat bahwa kelas B memiliki lebar data yang paling besar, artinya terdapat perbedaan atau variasi yang lebih besar di dalam kelas tersebut dibandingkan dengan kelas-kelas lainnya. Sebaliknya, kelas C memiliki rentang skor paling kecil di antara

ketiganya. Dalam hal ini, satu skor yang sama (misalnya, 4) dapat dimaknai secara berbeda berdasarkan nilai *range* tiap kelas.

Satu hal yang perlu diingat adalah bahwa variasi skor yang digambarkan dalam *range* hanya menunjukkan perbedaan antara yang mendapatkan nilai paling tinggi dan yang mendapatkan nilai paling rendah. Dari nilai *range* tersebut kita tidak memiliki informasi mengenai seberapa besar ukuran variabilitas (atau seberapa bervariasi) sebuah set data. Untuk mendapatkan gambaran ini, kita menggunakan ukuran penyebaran data berikutnya, yaitu varians.

8.2 Varians

Varians (s^2) adalah ukuran penyebaran data yang menunjukkan **seberapa jauh nilai-nilai dalam suatu kumpulan data menyimpang dari nilai *mean***. Varians dihitung dengan menjumlahkan kuadrat selisih setiap nilai (X) terhadap *mean* (\bar{x}), kemudian dibagi dengan jumlah data (N) (untuk populasi) atau jumlah data dikurangi satu ($n-1$) (untuk sampel). Dapat juga ditulis sebagai:

$$s^2 = \frac{\sum (X - \bar{x})^2}{N - 1}$$

Hasil varians menunjukkan “rata-rata kuadrat penyimpangan” dari *mean*, sehingga semakin besar nilai varians, semakin besar pula variasi data di sekitar *mean*. Dengan kata lain, varians juga menggambarkan **homogenitas** data, di mana semakin kecil varians maka semakin kecil perbedaan antar poin data, dan sebaliknya semakin besar varians semakin besar pula perbedaan antar poin data.

Sebagai ilustrasi, misalnya terdapat data set skor skala sikap dari dua kelompok partisipan yang berbeda (a & b), dengan masing-masing sebaran data sebagai berikut:

Kelompok a	6	6	6	6	7	7	7	7	7	8	8	8	$\bar{x}=6.9$
Kelompok b	2	3	5	5	6	6	6	7	9	9	10	12	$\bar{x}=6.7$

Untuk dapat memperoleh nilai varians, kita perlu menghitung simpangan atau selisih dari setiap data poin terhadap mean kemudian dikuadratkan, seperti pada **Tabel 8.3**.

Tabel 8.3: Perhitungan simpangan dan varians dua kelompok

Kelompok a			Kelompok b		
Skor (X)	Simpangan ($X - \bar{x}$)	Kuadrat simpangan ($(X - \bar{x})^2$)	Skor (X)	Simpangan ($X - \bar{x}$)	Kuadrat simpangan ($(X - \bar{x})^2$)
6	-0.9	0.81	2	-4.7	22.09
6	-0.9	0.81	3	-3.7	13.69
6	-0.9	0.81	5	-1.7	2.89
6	-0.9	0.81	5	-1.7	2.89
7	0.1	0.01	6	-0.7	0.49
7	0.1	0.01	6	-0.7	0.49
7	0.1	0.01	6	-0.7	0.49
7	0.1	0.01	7	0.3	0.09
7	0.1	0.01	9	2.3	5.29
8	1.1	1.21	9	2.3	5.29
8	1.1	1.21	10	3.3	10.89
8	1.1	1.21	12	5.3	28.09
$\Sigma(X - \bar{x})^2$		6.92	$\Sigma(X - \bar{x})^2$		92.68
$s^2 = \frac{\Sigma(X - \bar{x})^2}{N - 1}$		0.6	$s^2 = \frac{\Sigma(X - \bar{x})^2}{N - 1}$		8.4

Dari hasil penghitungan tersebut, kita menemukan perbedaan varians yang cukup besar antara kedua kelompok, meskipun *mean* keduanya tidak jauh berbeda. Hal ini menandakan bahwa kelompok b memiliki sebaran data yang jauh lebih beragam (heterogen) dibandingkan kelompok a (lihat Gambar 8.1). Oleh karena itu, pemaknaan terhadap nilai *mean* tiap kelompok juga berbeda, relatif terhadap variansnya masing-masing.

Varians memiliki fungsi penting dalam memahami keragaman atau variasi data di sekitar nilai rata-rata. Informasi ini sangat berguna untuk a) menilai konsistensi data (misalnya, dua kelompok dengan rata-rata yang sama bisa memiliki varians yang berbeda; kelompok dengan varians kecil berarti anggotanya lebih homogen.) dan b) dasar dari analisis statistik lanjutan, di mana varians menjadi komponen penting dalam berbagai teknik analisis, seperti standar deviasi, analisis varians (*ANOVA*), uji-t, dan regresi. Dengan demikian, varians bukan hanya ukuran penyebaran, tetapi juga alat untuk mengevaluasi struktur dan kualitas data sebelum melakukan interpretasi atau pengambilan keputusan lebih lanjut.

8.3 Standar Deviasi

Standar deviasi (s) adalah ukuran penyebaran data yang menunjukkan **rata-rata penyimpangan (deviasi) nilai data dari *mean***. Ukuran ini memberikan gambaran yang lebih intuitif tentang seberapa besar variasi dalam data. Artinya, semakin besar standar deviasi, semakin lebar sebaran data dari nilai tengahnya. Standar deviasi diperoleh dengan mengambil akar kuadrat dari varians:

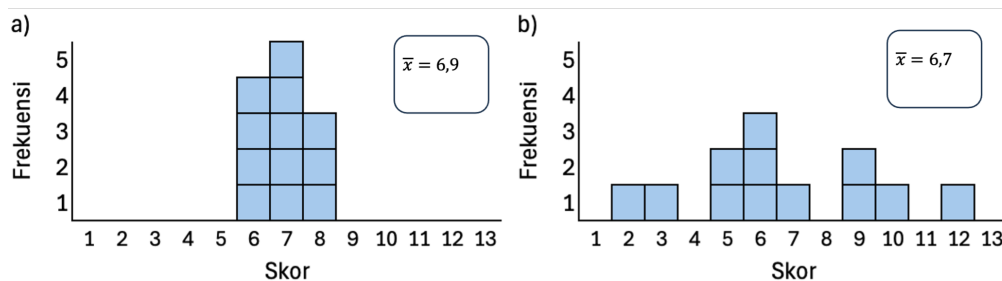
$$s = \sqrt{s^2}$$

Dengan menggunakan data pada pembahasan varians, kita dapat menghitung standar deviasi dari data tiap kelompok, yaitu:

$$\text{Kelompok a: } s = \sqrt{s^2} = \sqrt{0,6} = 0,77$$

$$\text{Kelompok b: } s = \sqrt{s^2} = \sqrt{8,4} = 2,90$$

Hasil penghitungan standar deviasi di atas memperkuat pemahaman bahwa Kelompok a lebih homogen ($s = 0,77$) dibandingkan Kelompok b yang lebih bervariasi ($s = 2,90$). Meskipun informasi ini serupa dengan yang diperoleh dari varians (0,6 vs 8,4), standar deviasi lebih mudah diinterpretasikan karena satuannya kembali ke satuan asli data, tidak dalam bentuk kuadrat seperti varians. Dengan demikian, standar deviasi memberikan gambaran yang lebih intuitif tentang jarak rata-rata setiap data dari *mean*, sehingga lebih sering digunakan dalam pelaporan dan interpretasi hasil statistik.



Gambar 8.1: Visualisasi data dengan: a) varians kecil & b) varians besar


Bab 9

Bentuk Distribusi Data

Setiap nilai dalam sekumpulan data memiliki frekuensi kemunculan yang berbeda-beda; nilai ekstrem biasanya muncul lebih jarang, sedangkan nilai yang mendekati *mean* lebih sering muncul. Pola ini membentuk **distribusi data**, yang jika digambarkan dalam grafik seperti poligon frekuensi, akan membentuk kurva. Pada distribusi yang ideal, yaitu **distribusi normal**, kurva berbentuk lonceng (*bell-shaped*) dan **simetris** di sekitar nilai ukuran pemusatan data seperti *mean* atau median. Namun, pada kenyataannya, data bisa saja miring (*skewed*) jika nilai-nilai terkonsentrasi di satu sisi, atau memiliki kurtosis jika kurvanya lebih runcing atau lebih datar dari distribusi normal. Pemahaman tentang bentuk distribusi ini penting karena banyak analisis statistik, terutama yang bersifat inferensial, mengasumsikan bahwa data terdistribusi normal. Untuk itu, bagian-bagian berikut akan membahas lebih lanjut mengenai **kurva normal**, **skewness**, **kurtosis**, dan **z-score** sebagai alat untuk menstandarkan data.

9.1 Kurva Normal

Seperti telah disampaikan sebelumnya, distribusi data dapat dikatakan normal jika kurvanya membentuk lonceng dan simetris. Pada distribusi data yang demikian, frekuensi dari setiap nilai **data tersebar secara simetris** antara yang terletak di atas tendensi sentral dan yang di bawah tendensi sentral. Data tersebar 50% di atas dan 50% di bawah tendensi sentral, dengan frekuensi yang semakin mengecil pada nilai data yang semakin ekstrem, baik yang kecil maupun yang besar (lihat Gambar 9.1).




Gambar 9.1: Bentuk kurva normal

Pada kurva normal, tiga pengukuran data terpusat (*mean*, median, dan modus) berada pada satu titik atau nilai yang relatif sama. Dari Gambar 9.1 dapat lebih terlihat jelas bahwa 50% data terse-

bar di atas tendensi sentral dan 50% data tersebar di bawah tendensi sentral, di mana semakin jauh dari tendensi sentral maka semakin sedikit frekuensinya.

Untuk menjawab masalah-masalah tertentu, kita perlu mencari besaran frekuensi sebuah nilai atau cakupan nilai berdasarkan sebaran data yang ada. Misalnya, kita ingin memperkirakan ada berapa jumlah mahasiswa yang nilai ujiannya antara 70 dan 85, di mana nilai *mean* = 80 *SD* = 5, dan *N* = 250. Dengan memanfaatkan informasi standar deviasi (*s*), proporsi frekuensi data pada distribusi normal dapat kita hitung berdasarkan luas area dalam kurva. Gambar 9.2 menunjukkan besaran proporsi frekuensi pada data dilihat dari luas area berdasarkan nilai standar deviasi.



Gambar 9.2: Proporsi sebaran data pada kurva normal

Dari kurva normal yang ditampilkan pada Gambar 3.3, kita dapat mengetahui bahwa setiap belahan kurva dibagi menjadi 4 area berdasarkan standar deviasi, yaitu (1) *mean* – ± 1 *SD* (34,1%), 1 *SD* – 2 *SD* (13,6%), 2 *SD* – 3 *SD* (2,1%), dan > 3 *SD* (0,1%). Artinya, proporsi terbanyak dari data adalah nilai-nilai yang mendekati *mean*, dan sebaliknya, semakin jauh dari *mean* maka proporsinya semakin kecil, terutama untuk nilai-nilai ekstrem ($> \pm 3$ *SD*).

Proporsi frekuensi data dengan nilai antara *mean* hingga 1 *SD* di bawah *mean* adalah sebesar 34,1% dari keseluruhan data, begitu juga dengan yang 1 *SD* di atas *mean*. Selanjutnya, jika kita ingin mengetahui proporsi frekuensi data antara *mean* hingga 2 *SD* di atas *mean*, maka kita menjumlahkan proporsi (*mean* – 1 *SD*) + (1 *SD* – 2 *SD*) = 34,1% + 13,6% = 47,7%.

Dengan demikian, untuk menjawab pertanyaan sebelumnya (proporsi mahasiswa yang memperoleh nilai ujian 70 (X_1) – 85 (X_2)) dengan *mean* = 80, *SD* = 5, dan *N* = 250, maka kita menghitungnya dengan mencari besaran *SD* dari batas bawah dan atas rentang skor:

$$X_1 - \text{mean} = 70 - 80 = -10; \text{ karena } SD = 5, \text{ maka skor } 70 = -2SD$$

$$X_2 - \text{mean} = 85 - 80 = 5; \text{ karena } SD = 5, \text{ maka skor } 85 = 1SD$$

$$\text{Maka, proporsi } X_1 - X_2 = (\text{proporsi } -2SD - \text{mean}) + (\text{proporsi mean} - 1SD)$$

$$= (13,6\% + 34,1\%) + (34,1\%)$$


$$= 81,8\%$$

Sehingga, jumlah mahasiswa dengan skor antara 70 – 85 = 81,8% \times 250 orang = 204 orang (pembulatan).

9.2 Skewness

Data pada sampel yang diambil dari populasi penelitian tidak selalu terdistribusi secara normal. Sebaran yang tidak normal ini seringnya terjadi pada sekumpulan data yang memiliki nilai ekstrem (*outlier*) yang proporsinya cukup jauh melebihi data yang tersebar secara normal. Besarnya *outlier* ini membuat sebaran data seolah-olah terpusat di bawah nilai tengah, atau sebaliknya terpusat di atas nilai tengah.

Jika data yang tersebar secara normal membentuk kurva berbentuk lonceng yang simetris, maka **data yang tidak normal** tersebut bisa membentuk **kurva yang miring** atau juling (*skewed*). Arah kemiringan (*skewness*) kurva bergantung pada besaran frekuensi data yang menyimpang dari nilai tengah. Jika frekuensi nilai yang berada di bawah *mean* jauh lebih kecil daripada frekuensi nilai di atas *mean*, maka puncak kurva akan condong ke kanan, yang disebut sebagai *skew* negatif (Gambar 9.3a). Sebaliknya, jika frekuensi nilai yang berada di bawah *mean* jauh lebih besar daripada frekuensi nilai di atas *mean*, maka puncak kurva akan condong ke kiri, yang disebut sebagai *skew* positif (Gambar 9.3b).



Gambar 9.3: Distribusi skewed

Terdapat dua cara yang umum digunakan untuk mengetahui arah kemiringan (*skewness*) dari sebuah distribusi data, yaitu dengan (a) menggunakan rumus Pearson, dan (b) membandingkan nilai-nilai ukuran pemusatan data.


1. Rumus Pearson:

$$\text{Skewness} = 3 \times \frac{\text{Mean} - \text{Median}}{\text{SD}}$$

Jika hasil penghitungan nilai *skewness* adalah positif, maka disebut dengan kurva *skewed* positif. Jika hasil hitungnya negatif, maka disebut dengan kurva *skewed* negatif. Apabila hasil hitungnya (mendekati) nol, maka disebut dengan kurva normal. Tidak ada angka pasti, seberapa dekat dengan nol dapat disebut sebagai kurva normal, tetapi kesepakatan umum adalah $\pm 0,5$.

2. Membandingkan nilai ukuran pemusatan data


Jika *mean* lebih kecil dari median, maka bentuk distribusinya adalah *skewed* negatif. Sebaliknya, jika *mean* lebih besar dari median, maka bentuk distribusinya adalah *skewed* positif. Namun, jika *mean*, median, dan modus berada pada satu titik yang relatif sama atau berdekatan, maka bentuk distribusi datanya adalah normal (Gambar 9.4).



Gambar 9.4: Skewness data berdasarkan lokasi tendensi sentral

9.3 Kurtosis

Kurtosis adalah seberapa **berbeda bentuk kurva dari kurva normal**, dilihat dari seberapa tebal-tipis bagian ekor dari kurva tersebut. Selain dilihat dari ekor kurva, kurtosis sebenarnya juga menunjukkan seberapa tajam bentuk puncak dari kurva. Terdapat tiga bentuk kurtosis, yaitu normal, ekor panjang (**heavy-tailed**) dan ekor pendek (**light-tailed**) (Gambar 9.5).



Gambar 9.5: Visualisasi kurtosis dalam distribusi data

Kurtosis pada distribusi data yang normal adalah ketika ekor kurva tersebar secara proporsional dan puncak kurva tidak terlalu curam maupun terlalu landai. Jika nilai kurtosis > 0 , maka kurva akan memiliki ekor yang pendek dan puncak yang curam, menandakan data menumpuk di nilai-nilai sekitar nilai tengah. Sebaliknya, jika nilai kurtosis < 0 maka ekor kurva akan memanjang dan puncaknya melandai, yang artinya hampir seluruh nilai memiliki frekuensi atau jumlah kejadian yang serupa. Kurva yang menunjukkan baik ekor panjang maupun ekor pendek menandakan bahwa data tidak terdistribusi secara normal.

9.4 Z-Score

z-score, yang dikenal juga dengan nama **skor baku**, menunjukkan **posisi sebuah skor** dibandingkan dengan rata-rata dalam satuan standar deviasi. Dengan kata lain, *z-score* menyatakan posisi relatif suatu nilai (X) dalam distribusi data. $z = 0$ berarti nilai tersebut tepat di *mean*, *z-score* negatif menandakan bahwa nilainya lebih rendah dari *mean*, dan *z-score* positif berarti nilainya di atas *mean*. *z-score* dapat dihitung dengan cara:

$$z = \frac{X - \bar{x}}{SD}$$

Tujuan utama penggunaan *z-score* adalah untuk menstandarkan data, sehingga memungkinkan perbandingan antar nilai dari distribusi yang berbeda. Sebagai analogi, kita tidak bisa menilai mana yang memiliki nilai yang lebih tinggi antara nilai dua mata uang yang berbeda (misalnya, 10 Rupee India dengan 10 Baht Thailand) tanpa mengkonversinya ke dalam satuan mata uang yang sama atau standar.

Dalam hal data, dua nilai dari distribusi yang berbeda (misalnya, nilai 8 pada subtes aritmatika dan nilai 8 pada subtest logika numerikal) bisa jadi memiliki posisi yang berbeda dalam distribusi data masing-masing, sehingga tidak dapat dibandingkan secara langsung. Oleh karena itu, kedua nilai tersebut perlu ditransformasi ke *z-score* agar memiliki satuan yang sama untuk dapat dibandingkan.

z-score juga bermanfaat dalam mendeteksi *outlier*, serta dalam berbagai analisis statistik lanjutan seperti uji hipotesis dan analisis distribusi normal. Karena *z-score* mengubah data ke skala yang seragam, ia menjadi alat penting dalam interpretasi dan generalisasi hasil penelitian.

Bagian IV

STATISTIK INFERENSIAL

Bagian V
PERBEDAAN RATA-RATA DUA
KELOMPOK

Bagian VI

**MEMBANDINGKAN RATA-RATA
TIGA ATAU LEBIH KELOMPOK**

Bagian VII

ANALISIS KORELASI

Bagian VIII

MODEL REGRESI LINEAR

Daftar Pustaka

- Buuren, S. van. (2018). *Flexible Imputation of Missing Data*. CRC Press.
- Coolican, H. (2014). *Research methods and statistics in psychology* (hlm. 773). Psychology Press, Taylor & Francis Group.
- Cowles, M. (2000). *Statistics in Psychology: An Historical Perspective*. Psychology Press.
- Dancey, C. P., & Reidy, J. (2017). *Statistics without maths for psychology* (7th ed.). Pearson Education Limited.
- Gelfond, J. A. L., Klugman, C. M., Welty, L. J., Heitman, E., Loudon, C., & Pollock, B. H. (2014). How to Tell the Truth with Statistics: The Case for Accountable Data Analyses in Team-based Science. *Journal of translational medicine & epidemiology*, 2.
- Gravetter, F. J., & Wallnau, L. B. (2017). *Statistics for the Behavioral Sciences*. Cengage Learning.
- Salsburg, D. (2002). *The lady tasting tea: how statistics revolutionized science in the twentieth century*. Henry Holt; Company.
- Tabachnick, B. G., & Fidell, L. S. (2014). *Using Multivariate Statistics* (6th ed.). Pearson Education Limited.

Indeks

Data, 13
Statistik, 6

Statistik deskriptif, 9
Statistik inferensial, 9